


人工智能引论¹

第2章 智能体²

授课教师：李静瑶³



“养龙虾”到底是啥²


“养龙虾”是2026年3月爆火的网络热词，核心是部署、调教开源AI智能体OpenClaw，和水产养殖无关。³

一、先搞懂：它到底是什么⁴

OpenClaw = 能自己动手操作电脑 / 手机的AI打工仔⁶

1. 普通AI⁷

- 只给文字答案⁹
- 不碰设备¹⁰



2. 龙虾AI⁸

- 你发指令，它自己打开软件、点鼠标、敲键盘、自动完成¹²



3. 图标是红色龙虾，网友戏称“养龙虾”¹⁴

养龙虾去啦!¹⁶



养龙虾去啦!¹⁸



二、它能帮你干啥（最实用场景）¹⁹



文件管理:²¹

自动整理桌面、分类文件、备份、重命名、PDF转文字²²



办公自动化:²⁴

写周报、做表格、发邮件、整理聊天记录、生成报告²⁵



信息处理:²⁷

联网搜索、网页抓取、内容总结、监控数据²⁸



定时任务:³⁰

每天9点发日报、每周自动备份、定时提醒³¹



多端操作:³³

绑定微信 / 钉钉 / 飞书，聊天框直接发指令³⁴

“养龙虾”爆火，官方发布风险提示！²

新华社 2026年3月10日 20:06 北京 887人³



近期，OpenClaw（“小龙虾”，曾用名Clawdbot、Moltbot）应用下载与使用情况火爆，国内主流云平台均提供了一键部署服务。此款智能体软件依据自然语言指令直接操控计算机完成相关操作。为实现“自主执行任务”的能力，该应用被授予了较高的系统权限，包括访问本地文件系统、读取环境变量、调用外部服务应用程序编程接口（API）以及安装扩展功能等。然而，由于其默认的安全配置极为脆弱，攻击者一旦发现突破口，便能轻易获取系统的完全控制权。⁵



录²

- 1 智能体和环境¹
- 2 正确的行为 — 理性的概念³
- 3 环境的性质⁴
- 4 智能体的结构⁵
- 5 AI Agent 商业化⁶




智能体 (Intelligent Agent) 定义的演变:²

- 15世纪, “one who acts” 执行动作的人/物, “effective, powerful” 有效的, 强大的³
- 1550年, “any natural force or substance which produces a phenomenon” 产生一个现象的力量或物质⁴
- 1590年, “deputy, representative” 代理⁵
-



智能体 (Intelligent Agent) 定义的演变:²


- Agent 概念由麻省理工学院的认知科学家与人工智能先驱的Marvin Minsky在 “Society of Mind (心智社会)” 一书中提出，将生物界个体社会行为的概念引入到计算机学科领域 (1986)³
- 2025年11月，“智能体” 入选2025年度十大科普热词⁴
- 2026年3月5日，《2026年国务院政府工作报告》提出，打造智能经济新形态，促进新一代智能终端和智能体加快推广⁵





智能体:²

- 任何通过**传感器** (sensor) 感知环境 (environment) 并通过**执行器** (actuator) 作用于该环境的事物都可以被视为智能体³



- 输入：感知序列**⁵
- 映射：智能体函数（智能体程序）**⁶
- 输出：执行动作并影响环境**⁷




智能体案例:²

分类	传感器	执行器
人类智能体	眼睛、耳朵、皮肤	手脚、声道
机器人智能体	摄像头、红外测距仪	马达
软件智能体	键盘、鼠标、文件	屏幕、打印机、文件

智能体和环境¹

案例：真空吸尘器世界²


- 智能体：吸尘器³
- 环境：两个房间A和B（干净或尘土）⁴
- 传感器：位置、内容⁵
- 执行器：左移、右移、吸尘、等待⁶



不同版本的真空吸尘器世界允许不同的规则，例如智能体可以感知什么，它的动作是否总是成功等⁸

智能体函数：描述智能体的行为，将任意给定的感知序列映射为行动²

感知序列	动作
[A, 干净]	右移
[A, 尘土]	吸尘
[B, 干净]	左移
[B, 尘土]	吸尘
[A, 干净], [A, 干净]	右移
[A, 干净], [A, 尘土]	吸尘
...	...
[A, 干净], [A, 干净], [A, 干净]	右移
[A, 干净], [A, 干净], [A, 尘土]	吸尘
...	...



真空吸尘器世界的简单智能体函数的部分表项。除非限制可能感知序列的长度，否则该表的大小是无限的⁵



理性的概念¹

理性的行为:²

- 理性 = 正确 = 合理³
- 结果主义：通过结果来评估智能体的行为⁴
- 智能体的动作序列导致环境经历一系列状态，如果环境状态的变化是合理的，智能体表现良好，则动作序列是理想的⁵
- 环境状态而不是智能体的状态，如果从智能体的角度定义，智能体可以达到完美理性，它只需要自我欺骗说环境是完美的⁶
 - 服务机器人在虚拟世界和现实世界的表现⁷

理性的概念¹

判断智能体理性的标准:²


- 定义成功标准的性能度量³
- 智能体对环境的先验认知⁴
- 智能体可以完成的行动⁵
- 智能体截止到此时的感知序列⁶

理性智能体的定义: 对于每个可能的感知序列, 给定感知序列提供的证据和智能体拥有的先验知识, 理性智能体应选择一个期望最大化其性能度量的动作⁷

理性的概念¹

性能度量:²

- 吸尘量多少: 吸尘——倒回——吸尘...³
- 清洁方格的数量: 来回吸尘永远停不下来⁴
- 最快把两个格子清理干净⁵
- 如果两个Agent一个一直匀速工作, 另一个短期高效工作、长期休息⁷



理性的判断案例:²

性能度量	每个时间步对不干净的房间“吸尘”奖励1分，生命周期为1000个时间步
环境的先验知识	环境的地形已知，房间干净与否（灰尘的分布）和 Agent 的初始位置未知
可执行的动作	“左移”和“右移”使 Agent 向左或向右移动，但不会移出环境，否则 Agent 会保持原位；干净的房间保持干净，“吸尘”会使当前房间干净
感知序列	Agent 能正确感知房间位置和所在房间是否干净

理性的判断案例:²

性能度量	每个时间步对不干净的房间“吸尘”奖励1分，生命周期为1000个时间步， 移动 Agent 惩罚1分
环境的先验知识	环境的地形未知 ，房间干净与否（灰尘的分布）和 Agent 的初始位置未知
可执行的动作	“左移”和“右移”使 Agent 向左或向右移动，但不会移出环境，否则 Agent 会保持原位； 干净的房间可能被弄脏 ，“吸尘”会使当前房间干净
感知序列	Agent 能正确感知房间位置和所在房间是否干净



全知、学习和自主²:

- 理性：使期望的性能最大化³
- 全知：使实际的性能最大化⁴
- 自主性：一个理性的智能体应该是自主的，它应该学习如何弥补部分或不正确的先验知识（信息收集）⁵

环境的性质¹

任务环境 PEAS:²

- 性能——Performance³
- 环境——Environment⁴
- 执行器——Actuator⁵
- 传感器——Sensor⁶

判断智能体理性的标准:⁷

- 定义成功标准的性能度量⁸
- 智能体对环境的先验认知⁹
- 智能体可以完成的行动¹⁰
- 智能体截止到此时的感知序列¹¹

自动驾驶出租车司机任务环境的PEAS描述²

智能体类型	性能度量	环境	执行器	传感器
自动驾驶出租车司机	安全、速度快、合法、舒适旅程、最大化利润、对其他道路用户	道路、其他交通工具、警察、行人、客户、天气	转向器、加速器、制动、信号、喇叭、显示、语音	摄像头、雷达、速度表、GPS、发动机传感器、加速度表、麦克风、触摸屏

智能体类型及其PEAS描述的示例²

智能体类型	性能度量	环境	执行器	传感器
医学诊断系统	治愈患者、降低费用	患者、医院、工作人员	用于问题、测试、诊断、治疗的显示器	用于症状和检验结果的触摸屏/语音输入
卫星图像分析系统	正确分类对象和地形	轨道卫星、下行链路、天气	场景分类显示器	高分辨率数字照相机
零件选取机器人	零件在正确箱中的比例	零件输送带、箱子	有关节的手臂和手	摄像头、触觉和关节角度传感器
提炼厂控制器	纯度、产量、安全	提炼厂、原料、操作员	阀门、泵、加热器、搅拌器、显示器	温度传感器、气压传感器、流量传感器、化学传感器
交互英语教师	学生的考试分数	一组学生、考试机构	用于练习、反馈、发言的显示器	键盘输入、语音



完全可观测与部分可观测:²

- 完全可观测：智能体传感器在每个时间点都能访问环境的完整状态³
- 有效的完全可观测：传感器能检测到与动作选择相关的所有方面（相关取决于性能度量标准）⁴
- 部分可观测：由于传感器噪声大、传感器精度或稳定性等因素导致不能获取所有和行动有关的信息⁵
- 不可观测：智能体没有传感器（搜索）⁶



单智能体与多智能体:²

- 协作完成任务/单独完成任务，是否有相互影响³
 - 一个司机在路上开车，他和行人之间、和其他司机之间?⁴
 - 一场足球比赛，球员之间，球员和观众之间?⁵
- 竞争性多智能体：一方胜利是另一方的失败（象棋）⁶
- 部分合作的多智能体：开车时避免碰撞会使所有智能体的性能度量最大化⁷
- 部分竞争的多智能体：一个车位只能停一辆车⁸



环境的性质¹

确定性与非确定性:²

- 环境的下一个状态完全由当前的状态和智能体执行的动作决定，则说环境是确定的，否则是非确定的³
 - 打字
 - 汽车驾驶
- 一般来说，智能体在完全可观测的环境中不需要担心不确定性，而部分可观测的环境可能是非确定的。大多数真实的环境都是非确定环境⁴
- “随机”说明后果是不确定但可以用概率量化的，而“非确定”的环境中行动的结果与概率无关⁵

环境的性质¹

回合式与序贯式:²

- 回合式（片段式）：智能体的经历被分成了一个个原子片段。在每个片段中智能体感知信息并完成单个行动，下一个片段不依赖以前片段中采取的行动³
 - 分类任务⁴
 - 装配线上检验次品零件的机器⁵
- 序贯式（延续式）：当前的决策会影响到所有未来的决策⁶
 - 下棋⁷
 - 汽车驾驶⁸

环境的性质¹

静态与动态:²

- 如果环境在智能体计算的时候发生了变化, 那么该环境是动态的, 否则是静态的³
 - 驾驶汽车
 - 数独游戏
- 静态不需要考虑时间的流逝, 动态需要持续地做出决策⁴
- 半动态: 环境本身不会随着时间的推移而改变, 但智能体的性能分数会改变⁵
 - 时钟计时情况下的象棋



环境的性质¹

离散与连续:²

- 环境的状态、时间的处理方式以及智能体的感知信息和行动，都有离散和连续之分³
 - 象棋中的状态是有限的，感知信息和行动是离散的⁴
 - 摄像头中的信号是离散的，但处理时表示的是连续变化的亮度和位置⁵

环境的性质¹

已知与未知:²

- 区分的不是环境本身，而是指智能体对环境“物理定律”的认知状态³
- 已知环境中，所有行动的后果是给定的⁴
- 未知环境中，智能体需要学习环境是如何工作的，才能做出正确决策⁵
- 已知环境可能是部分可观测的⁶
 - 纸牌游戏⁷
- 未知环境可能是完全可观测的⁸
 - 全新的电子游戏⁹

环境的性质¹

智能出租车Agent:²

性能³

- 安全⁴
- 目标⁵
- 效益⁶
- 合法⁷
- 舒适⁸

环境⁹

- 道路¹⁰
- 交通¹¹
- 行人¹²
- 天气¹³

执行器¹⁴

- 方向盘¹⁵
- 油门¹⁶
- 刹车¹⁷
- 喇叭¹⁸
- 显示器¹⁹

传感器²⁰

- 摄像头²¹
- 加速度计²²
- 仪表²³
- 引擎传感器²⁴
- GPS²⁵

完全可观测或部分可观测	单Agent或多Agent	确定或非确定	片段或延续	静态或动态	离散或连续	已知或未知
部分可观测	多Agent	非确定	延续	动态	连续	未知

26

环境的性质¹

智能购物Agent:²

性能³

- 价格⁴
- 质量⁵
- 合适⁶
- 效率⁷

环境⁸

- 网站⁹
- 厂商¹⁰
- 货主¹¹

执行器¹²

- 商品展示¹³
- 商品链接¹⁴
- 购买填单¹⁵

传感器¹⁶

- 文字¹⁷
- 图像¹⁸
- js脚本¹⁹

完全可观测或部分可观测	单Agent或多Agent	确定或非确定	片段或延续	静态或动态	离散或连续	已知或未知
部分可观测	单Agent	非确定	延续	动态	离散	未知



任务环境	可观测	智能体	确定性	回合式	静态	离散
填字游戏	完全	单	确定性	序贯	静态	离散
限时国际象棋	完全	多	确定性	序贯	半动态	离散
扑克	部分	多	非确定性	序贯	静态	离散
西洋双陆棋	完全	多	非确定性	序贯	静态	离散
驾驶出租车	部分	多	非确定性	序贯	动态	连续
医疗诊断	部分	单	非确定性	序贯	动态	连续
图片分析	完全	单	确定性	回合式	半动态	连续
零件选取机器人	部分	单	非确定性	回合式	动态	连续
提炼厂控制器	部分	单	非确定性	序贯	动态	连续
交互英语教师	部分	多	非确定性	序贯	动态	离散

智能体的结构¹




智能体 = 架构 + 程序²

- 智能体架构: 程序运行的具有传感器和执行器的计算设备³
- 智能体程序: 智能体函数的实现⁴


智能体程序类型:²

- 简单反射型智能体³
- 基于模型的反射型智能体⁴
- 基于目标的智能体⁵
- 基于效用的智能体⁶
- 学习型智能体⁷





简单反射型智能体：根据当前感知选择动作，忽略感知历史的其余部分²



感知序列	动作
[A, Clean]	Right
[A, Dirty]	Suck
[B, Clean]	Left
[B, Dirty]	Suck
[A, Clean], [A, Clean]	Right
[A, Clean], [A, Dirty]	Suck
...	...
[A, Clean], [A, Clean], [A, Clean]	Right
[A, Clean], [A, Clean], [A, Dirty]	Suck
...	...


4

function REFLEX-VACUUM-AGENT([location,status]) returns 一个动作⁵

if status = Dirty then return Suck⁶
else if location = A then return Right
else if location = B then return Left



基于模型的反射型智能体: 维护某种依赖于感知历史的内部状态²



function MODEL-BASED-REFLEX-AGENT(*percept*) **returns** 一个动作⁴

persistent: *state*, 智能体对世界状态的当前理解

transition_model, 关于下一个状态如何决定于当前状态和动作的描述⁵

sensor_model, 关于当前世界状态如何反映到智能体感知的描述

rules, 一组条件-动作规则

action, 最近的动作, 初始为空

state ← UPDATE-STATE(*state*, *action*, *percept*, *transition_model*, *sensor_model*)⁶


rule ← RULE-MATCH(*state*, *rules*)

action ← *rule*.ACTION

return *action*




基于目标的智能体: 添加目标信息, 寻找**实现目标**的动作序列 (搜索、规划)²






基于效用的智能体：添加效用函数，选择能够最大化其动作结果的期望效用的动作²





学习型智能体²





2023-2024 涌现的AI Agent项目：²

- 谷歌 Deepmind 推出的 robotic agent RoboCat, 利用机械臂自动执行各种工作³
- 亚马逊Amazon Bedrock Agents, 自动分解企业AI应用开发任务⁴
- AI独角兽Inflection开发的私人AI助理, 可以帮助完成订酒店等私人任务⁵
- 哥伦比亚大学发布了用于科研的AI Agent项目, GPT Researcher⁶

“至少有100个项目正致力于将AI Agent商业化, 近10万名开发人员正在构建自主Agent” (2024.03)⁷




- 大模型之战的下半场²
- ChatGPT 之后的下一个热点³
- AI 应用新时代的起点⁴
- OpenAI 创始成员Andrej Karpathy在黑客马拉松演讲中表示，相比大模型训练，OpenAI 内部目前更关注 Agent 领域⁵



每当有新的Agent论文出来的时候，团队都会很兴奋并且认真地讨论。你们（开发者们）都正站在 Agent 开发的最前沿，这个领域 OpenAI 也没什么积累（2023.06）⁸



AI 聊天机器人主要靠“说”来回答你的问题，而 AI Agent 则会“动”起来完成具体的任务，就像人类助理一样，在你忙不过来的时候替你完成一些工作，区别就是用AI来驱动而不是人脑驱动²





Agent = LLM + memory + planning skills + tool use²


- 记忆：ChatGPT-4等大模型记不住多次对话，增加“记忆”组件，让它时刻记着任务的内容³
- 规划：复杂任务难以一步到位，需要“规划”组件来负责任务分解，将总任务拆分为各项子任务⁴
- 工具：当任务需求超出大模型自身的能力范围时，就需要使用“工具”组件调用其它软件工具来执行⁵



初创公司 Seednapse AI 创始人提出构建AI 应用的五层基石理论²

- Models: 调用大模型API³
- Prompt Templates: 在提示词中引入变量以适应应用
户输入的提示模版⁴
- Chains: 对模型的链式调用, 以上一个输出为下
一个输入的一部分⁵
- Agent: 能自主执行链式调用, 以及访问外部工具⁶
- Multi-Agent: 多个Agent共享一部分记忆, 自主分⁸

工相互协作⁹





AutoGPT & BabyAGI: AI名称、描述和目标（执行速度慢、陷入死循环、开销过大等问题）（2023.04）²


A screenshot of the BabyAGI Streamlit web application. The interface is light green and contains several input fields and a button. On the left, there is a section for 'Your OpenAI API KEY' with a masked input field and an eye icon. The main section is titled 'BabyAGI Streamlit' and includes an 'Input Ultimate goal' field with a placeholder 's', an 'Input Where to start' field, and a 'Max iterations' field with a value of 3 and minus/plus buttons. A 'Run' button is at the bottom. The footer says 'Made with Streamlit'.

3



Sweep: 与Github 的 Issue 和 Pull request 场景整合, 自动“清扫”bug报告和功能请求, 直接完成对应代码²

Cursor: 一句话生成整个项目框架³





人工智能初创公司 HyperWriteAI 推出的数字助理 Personal Assistant (2023.08):²

- “第一个可以与浏览器交互操作的 AI 智能体”³
- “其他助手基于海量的知识来生成文本和答案，而我擅长的是搜索信息、导航到某个网站、填写表格以及与网页上的各种 ARIA 元素交互”⁴



⁵ Aidan Gomez  @aidangomezzz · 8月3日 ⁶

We're starting to get the first glimpses of real personal agents.

Really impressed by what Matt and team have built. ⁷

我们开始第一次看到真正的个人代理。⁸

Matt 和团队所构建的东西给人留下了深刻的印象。⁹



Personal Assistant 预定行程:²

- 告知出发地与目的地以及具体时间, Personal Assistant 会进入浏览器页面³
主动搜索符合要求的出行方案



What can I help you with today?⁵



- Personal Assistant 会挑选出几个较为合适的方案供你选择。选择后，你的行程就将预订成功²



³ These are the best options, based on your preferences and information.⁴



Personal Assistant 搜索和总结信息:²

- 发送命令³



⁴ Find the Techcrunch article about the HyperWrite AI Agent⁵ and summarize the information.



⁶ I'll get right on it!⁷




⁸ Please wait a moment, and I'll get started by redirecting⁹ your browser shortly...




Personal Assistant 搜索和总结信息:²

- 系统打开浏览器，在搜索框里自动输入相关要求，等待一段时间后，相关网页呈现出来³



Personal Assistant 写邮件:²


- 告知 Navigate to Gmail and send a creative one line email to xxx thanking her for pretty gift for my birthday³



Personal Assistant 买窗帘²




Personal Assistant 自主操作 ChatGPT，从单个提示开始构建网站²





Personal Assistant 订披萨、在 LinkedIn 选找合适的工程人选等²





Amazon Bedrock Agents: 在全托管基础模型服务的基础上，又把开发、部署²和管理等多个Agent 的能力打包集成



只用几次点击，搞定能执行任务的生成式AI应用⁴



Amazon Bedrock Agents: 除了自家的Amazon Titan大模型，还集结了擅长安全可控的Anthropic、擅长检索汇总信息的Cohere、以及专攻文生图的stability.ai等模型²





20

Amazon Bedrock > Agents > Create Agent²Step 1
Provide Agent details³Step 2
Select model⁴Step 3 - optional
Add Action groups⁵Step 4
Review and create⁶Select model⁷Model details⁸Anthropic⁹Claude V1¹¹

Next-gen AI assistant trained on helpful, honest, and harmless AI systems, Claude can help with summarization, search, creative writing, Q&A, coding, as well as take direction.

Note: The terms "Human:" and "Assistant:" will automatically be added to all prompts using Anthropic models to improve your results. [View details](#)

Instructions for the Agent¹³

Provide clear and specific instructions for the task the Agent will perform. You can also provide certain style and tone.¹⁴

You are an agent designed to help with processing insurance claims and managing pending paperwork.¹⁵

This instruction can have 40 to 800 characters.¹⁶

Cancel¹⁷

Send reminder to all policy holders with open claims and pending paper work¹⁹



21

There are currently two open insurance claims with the claim IDs "claim-123" and "claim-06". The policy holders for these claims have IDs "A134085" and "A645987" respectively. For both these open claims, reminders have been sent regarding the pending documents - Accident Report, Driver's License and Vehicle Registration. The status of sending these reminders is "In Progress".²²